



Университет ИТМО

Факультет ИТиП

Группа М3232

Лабораторная работа №4

Сопряжённые направления и методы Ньютона

Дисциплина: Методы оптимизации

Выполнили:

Дегтярев Александр Сергеевич

Надточий Ярослав Вадимович

Проверила: Матвеева М.В.

Содержание

1	Постановка задачи	2
2	Теоретические основы	3
2.1	Мотивация: ограничения градиентного спуска	3
2.2	Число обусловленности и его влияние	3
2.3	Линейный поиск и условия Вольфе	3
3	Описание методов	3
3.1	Метод сопряжённых градиентов (квадратичный CG)	3
3.2	Нелинейные методы CG (Флетчер–Ривз, Полак–Рибьер)	4
3.3	Метод Ньютона с разложением Холецкого	4
3.4	Метод Ньютона с выбором направления	4
3.5	Метод области доверия (Powell’s Dog Leg)	4
3.6	Квазиньютоновские методы: DFP и BFGS	5
3.7	L-BFGS (ограниченная память)	5
4	Результаты	6
4.1	Квадратичные функции: зависимость от размерности и обусловленности . . .	6
4.2	Траектории на 2D квадратичной функции	9
4.3	Тестовые функции	14
4.3.1	Функция Розенброка	14
4.3.2	Функция Химмельблау	18
4.4	Влияние размера памяти L-BFGS	22
5	Сравнение методов	24
6	Выводы	24

1 Постановка задачи

Исследовать методы второго порядка и квазиньютоновские методы для безусловной минимизации:

$$x^* = \arg \min_{x \in \mathbb{R}^n} f(x).$$

Реализованные методы:

1. Метод сопряжённых градиентов для квадратичных функций;
2. Метод нелинейных сопряжённых градиентов Флетчера–Ривса;
3. Метод нелинейных сопряжённых градиентов Полака–Рибьера;
4. Метод Ньютона с использованием разложения Холецкого;
5. Метод Ньютона с выбором направления;
6. Метод Powell's Dog Leg;
7. Квазиньютоновские методы DFP, BFGS и L-BFGS.

Также планировалось сравнение с `scipy.optimize.minimize(..., method='Newton-CG')`, однако в среде выполнения `scipy` не был установлен, поэтому данное сравнение не проводилось.

Для каждого метода фиксируются: количество итераций, вычислений функции, градиента и матрицы Гессе (если используется), а также причина остановки.

Модели задач

1. **Квадратичные функции.** Генератор выпуклых квадратичных функций:

$$f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle + c, \quad A = A^T \succ 0,$$

с заданной размерностью n и числом обусловленности $\kappa = \text{cond}(A)$. Матрица A строится как $A = Q^T \Lambda Q$, где Q — случайная ортогональная матрица, Λ — диагональная с собственными значениями от 1 до κ . Размерности: $n \in \{2, 10, 50, 100\}$, числа обусловленности: $\kappa \in \{1, 10, 100, 1000\}$.

2. **Двумерная квадратичная функция** с $n = 2$ и $\kappa = 10$ для визуализации траекторий из 5 различных начальных точек.

3. **Тестовые функции:**

- Функция Розенброка: $f(x, y) = (1 - x)^2 + 100(y - x^2)^2$, минимум в $(1, 1)$;
- Функция Химмельблау: $f(x, y) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2$, 4 минимума.

Критерий остановки: $\|\nabla f(x)\| \leq \varepsilon = 10^{-8}$, максимум 3000 итераций (4000 для L-BFGS memory).

2 Теоретические основы

2.1 Мотивация: ограничения градиентного спуска

Градиентный спуск первого порядка использует только информацию о направлении наискорейшего убывания $-\nabla f(x)$. Его скорость сходимости на квадратичных задачах ограничена отношением

$$\frac{\kappa - 1}{\kappa + 1},$$

где $\kappa = \lambda_{\max}/\lambda_{\min}$ — число обусловленности матрицы A . При $\kappa = 1000$ фактор сжатия составляет 0.998, и для уменьшения ошибки в 10^8 раз потребуется ~ 9200 итераций. Методы второго порядка используют информацию о кривизне (гессиан $\nabla^2 f$) и способны достигать квадратичной скорости сходимости, что принципиально ускоряет оптимизацию.

2.2 Число обусловленности и его влияние

Число обусловленности $\kappa(A) = \|A\| \cdot \|A^{-1}\|$ характеризует «вытянутость» линий уровня функции. При $\kappa = 1$ линии уровня — окружности, и все методы сходятся за 1–2 шага. При большом κ линии уровня — сильно вытянутые эллипсы: градиент указывает не в сторону минимума, а перпендикулярно длинной оси эллипса, что вызывает зигзагообразное поведение у методов первого порядка. Методы, использующие гессиан, масштабируют направление спуска обратной матрицей кривизны, компенсируя вытянутость.

2.3 Линейный поиск и условия Вольфе

Многие из реализованных методов используют линейный поиск для определения шага α_k . Условия Вольфе обеспечивают достаточное убывание функции (условие Армико) и ограничивают кривизну:

$$f(x_k + \alpha d_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T d_k, \quad |\nabla f(x_k + \alpha d_k)^T d_k| \leq c_2 |\nabla f(x_k)^T d_k|,$$

где $0 < c_1 < c_2 < 1$. Сильные условия Вольфе гарантируют существование допустимого шага для направления спуска и обеспечивают сходимость квазиньютоновских методов.

3 Описание методов

3.1 Метод сопряжённых градиентов (квадратичный CG)

Идея. На квадратичной функции $f(x) = \frac{1}{2}x^T A x - b^T x + c$ градиентный спуск создаёт зигзаги, потому что каждый следующий градиент ортогонален предыдущему направлению, но не учитывает все предыдущие. Метод CG строит направления $d_0, d_1, \dots$, которые попарно A -сопряжены ($d_i^T A d_j = 0$ при $i \neq j$), что гарантирует: каждый шаг минимизирует функцию в новом подпространстве, не портя результат предыдущих шагов.

Алгоритм. Начальное направление $d_0 = -g_0$. На каждом шаге:

$$\alpha_k = -\frac{g_k^T d_k}{d_k^T A d_k}, \quad x_{k+1} = x_k + \alpha_k d_k, \quad \beta_k = \frac{g_{k+1}^T A d_k}{d_k^T A d_k}, \quad d_{k+1} = -g_{k+1} + \beta_k d_k.$$

Свойство. Гарантированная сходимость за $\leq n$ итераций (точно для квадратичных). Не требует гессиана — матрица A используется только через произведение $A d_k$. Память $O(n)$.

3.2 Нелинейные методы CG (Флетчер–Ривз, Полак–Рибьер)

Идея. Обобщение квадратичного CG на произвольные гладкие функции. Поскольку для неквадратичных функций A -сопряжённость не определена, используется эвристическая формула для β_k , основанная только на градиентах.

Направление обновляется как $d_{k+1} = -g_{k+1} + \beta_k d_k$. Два варианта β_k :

$$\beta_k^{\text{FR}} = \frac{\|g_{k+1}\|^2}{\|g_k\|^2}, \quad \beta_k^{\text{PR}} = \frac{g_{k+1}^T (g_{k+1} - g_k)}{\|g_k\|^2}.$$

Различия. FR сохраняет сопряжённость вдали от минимума, но может «застревать» с малым шагом. PR при $\beta_k < 0$ автоматически перезапускается ($\beta_k := 0$), что часто ускоряет сходимость на сильно нелинейных функциях, но увеличивает общее число перезапусков.

Шаг α_k определяется линейным поиском с условиями Вольфе. На квадратичных функциях оба метода совпадают с классическим CG.

3.3 Метод Ньютона с разложением Холецкого

Идея. Минимизируем квадратичную модель функции в текущей точке:

$$f(x_k + d) \approx f(x_k) + g_k^T d + \frac{1}{2} d^T H_k d,$$

где $H_k = \nabla^2 f(x_k)$ — гессиан. Минимум достигается при $H_k d = -g_k$.

Почему Холецкий. Если H_k положительно определена ($H_k \succ 0$), система решается разложением $H_k = LL^T$, что стоит $O(n^3/3)$ операций и численно устойчиво.

Сходимость. Квадратичная: $\|x_{k+1} - x^*\| \leq C \|x_k - x^*\|^2$ вблизи x^* . Для квадратичных функций — точное решение за 1 итерацию ($H_k = A = \text{const}$).

Ограничение. Если H_k не положительно определена (седловая точка, максимум или вырожденность), разложение Холецкого не существует и метод не может определить направление спуска.

3.4 Метод Ньютона с выбором направления

Идея. Модификация метода Ньютона, которая обрабатывает случай, когда H_k не является положительно определённой. Алгоритм:

1. Попытаться решить $H_k d = -g_k$ через разложение Холецкого.
2. Если разложение не удалось — использовать направление антиградиента: $d = -g_k$.
3. Определить шаг α_k линейным поиском с условиями Вольфе.

Линейный поиск обеспечивает гарантированное убывание f , даже когда используется антиградиент. Метод комбинирует квадратичную скорость Ньютона вблизи минимума и глобальную сходимость градиентного спуска вдали.

3.5 Метод области доверия (Powell's Dog Leg)

Идея. Вместо линейного поиска ограничиваем шаг областью доверия — шаром радиуса Δ_k , в пределах которого квадратичная модель «заслуживает доверия»:

$$\min_d m_k(d) = f_k + g_k^T d + \frac{1}{2} d^T H_k d, \quad \|d\| \leq \Delta_k.$$

Два крайних случая:

- Если ньютоновский шаг $d^N = -H_k^{-1}g_k$ помещается в область ($\|d^N\| \leq \Delta_k$), используем его — максимальная скорость.
- Если нет, рассматриваем шаг Коши $d^C = -\frac{g_k^T g_k}{g_k^T H_k g_k} g_k$ (наискорейший спуск с оптимальным шагом по модели).

Dogleg аппроксимирует решение кусочно-линейной кривой от начала через d^C к d^N , выбирая точку пересечения с границей $\|d\| = \Delta_k$.

Адаптация радиуса. После шага вычисляется отношение $\rho_k = (f(x_k) - f(x_{k+1})) / (m_k(0) - m_k(d_k))$. Если ρ_k близко к 1 — модель хорошая, Δ увеличивается. Если ρ_k мало или отрицательно — шаг отклоняется, Δ уменьшается. Это обеспечивает глобальную сходимость без явного линейного поиска.

3.6 Квазиньютоновские методы: DFP и BFGS

Мотивация. Методы Ньютона требуют вычисления и хранения гессиана — $O(n^2)$ памяти и $O(n^2)$ или $O(n^3)$ операций на каждой итерации (для вычисления и факторизации). Квазиньютоновские методы строят аппроксимацию обратного гессиана $B_k \approx H_k^{-1}$, обновляя её по информации из предыдущих шагов, без явного вычисления H_k .

Общая схема. Направление спуска $d_k = -B_k g_k$. После шага обновляем B_k так, чтобы выполнялось секущее условие:

$$B_{k+1} y_k = s_k, \quad \text{где } s_k = x_{k+1} - x_k, \quad y_k = g_{k+1} - g_k.$$

DFP (Давидон–Флетчер–Пауэлл) — первая квазиньютоновская формула:

$$B_{k+1} = B_k - \frac{B_k y_k y_k^T B_k}{y_k^T B_k y_k} + \frac{s_k s_k^T}{y_k^T s_k}.$$

BFGS (Бройден–Флетчер–Гольдфарб–Шанно) — дуальная формула:

$$B_{k+1} = \left(I - \frac{s_k y_k^T}{y_k^T s_k} \right) B_k \left(I - \frac{y_k s_k^T}{y_k^T s_k} \right) + \frac{s_k s_k^T}{y_k^T s_k}.$$

Почему BFGS лучше DFP. BFGS более устойчив к ошибкам линейного поиска и числовым погрешностям: при неточном α_k обновление DFP может сильно исказить B_k , тогда как BFGS «самокорректируется» за несколько шагов. На практике BFGS рекомендуется как метод по умолчанию.

Сходимость. Суперлинейная: $\|x_{k+1} - x^*\| / \|x_k - x^*\| \rightarrow 0$. На квадратичных функциях накапливает точную H^{-1} за n шагов (свойство конечной сходимости).

Условие корректности. Обновление B_k сохраняет положительную определённую при $y_k^T s_k > 0$, что гарантируется условиями Вольфе. Если $y_k^T s_k \leq 0$, обновление пропускается.

3.7 L-BFGS (ограниченная память)

Проблема. BFGS хранит матрицу B_k размера $n \times n$ — при $n = 10^6$ это 8 ТБ в double. L-BFGS решает эту проблему: вместо матрицы хранит последние m пар (s_i, y_i) и вычисляет $B_k g_k$ «на лету» за $O(mn)$ операций с помощью алгоритма two-loop recursion.

Параметр m (размер памяти, обычно 3–20) определяет компромисс между качеством аппроксимации и расходом памяти. Больше m — точнее аппроксимация, но дороже итерация. Типичный выбор $m = 10$.

4 Результаты

4.1 Квадратичные функции: зависимость от размерности и обусловленности

Зачем этот эксперимент. Квадратичные функции — основной теоретический бенчмарк для методов оптимизации. На них точно известен минимум ($x^* = A^{-1}b$), можно контролировать сложность задачи через n и κ , и аналитически предсказать поведение каждого метода. Это позволяет проверить корректность реализации: метод Ньютона обязан сойтись за 1 итерацию, CG — за $\leq n$.

Что ожидаем. Методы, использующие точный гессиан, не должны зависеть от κ . Методы первого порядка (нелинейные CG) должны деградировать с ростом κ . Квазиньютоновские — занимать промежуточное положение.

Таблица 1: Число итераций на квадратичных функциях ($n = 2$)

Метод	$\kappa = 1$	$\kappa = 10$	$\kappa = 100$	$\kappa = 1000$
Quadratic CG	1	2	2	2
Nonlinear CG (FR)	1	41	2426	>3000
Nonlinear CG (PR)	1	35	>3000	>3000
Newton (Cholesky)	1	1	1	1
Newton (direction)	1	1	1	1
Dogleg	2	2	1	2
DFP	1	4	3	3
BFGS	1	6	3	3
L-BFGS	1	9	5	13

Таблица 2: Число итераций на квадратичных функциях ($n = 10$)

Метод	$\kappa = 1$	$\kappa = 10$	$\kappa = 100$	$\kappa = 1000$
Quadratic CG	1	10	12	14
Nonlinear CG (FR)	1	99	>3000	>3000
Nonlinear CG (PR)	1	61	>3000	>3000
Newton (Cholesky)	1	1	1	1
Newton (direction)	1	1	1	1
Dogleg	3	3	3	2
DFP	1	20	>3000	17
BFGS	1	19	19	>3000
L-BFGS	1	32	>3000	>3000

Таблица 3: Число итераций на квадратичных функциях ($n = 100$)

Метод	$\kappa = 1$	$\kappa = 10$	$\kappa = 100$	$\kappa = 1000$
Quadratic CG	1	33	90	221
Nonlinear CG (FR)	1	>3000	>3000	>3000
Nonlinear CG (PR)	1	>3000	>3000	>3000
Newton (Cholesky)	1	1	1	1
Newton (direction)	1	1	1	1
Dogleg	4	4	4	4
DFP	1	>3000	>3000	>3000
BFGS	1	>3000	>3000	>3000
L-BFGS	1	>3000	>3000	>3000

Методы Ньютона (Cholesky и direction) решают квадратичную задачу за 1 итерацию при любых n и κ . Квадратичный CG масштабируется линейно по κ (теоретически за $\leq n$ шагов). Нелинейные CG и квазиньютоновские методы теряют эффективность при росте n и κ .




Рис. 1: Зависимость числа итераций от числа обусловленности




Рис. 2: Зависимость числа итераций от размерности




Рис. 3: Число вычислений функции от числа обусловленности




Рис. 4: Число вычислений градиента от размерности

4.2 Траектории на 2D квадратичной функции

Двумерная квадратичная функция с $n = 2$, $\kappa = 10$. Выбрано 5 начальных точек, расположенных на разном расстоянии от минимума и в разных направлениях. Методы Ньютона делают один шаг прямо в минимум. Квазиньютоновские методы постепенно приближаются к квадратичной скорости по мере накопления информации о кривизне. Нелинейные CG демонстрируют зигзагообразные траектории при плохой обусловленности.




Рис. 5: Траектории оптимизации, начальная точка 1




Рис. 6: Траектории оптимизации, начальная точка 2




Рис. 7: Траектории оптимизации, начальная точка 3




Рис. 8: Траектории оптимизации, начальная точка 4




Рис. 9: Траектории оптимизации, начальная точка 5

4.3 Тестовые функции

Зачем этот эксперимент. Квадратичные функции не отражают трудности реальной оптимизации: нелинейность, несколько локальных минимумов, седловые точки, узкие долины. Тестовые функции Розенброка и Химмельблау — классические бенчмарки, демонстрирующие разные типы сложностей. Запуск из нескольких начальных точек позволяет оценить глобальную сходимость и устойчивость к выбору старта.

4.3.1 Функция Розенброка

Функция $f(x, y) = (1 - x)^2 + 100(y - x^2)^2$ имеет единственный минимум в $(1, 1)$, но оптимизация затруднена узкой параболической долиной: вдоль дна долины функция убывает очень медленно (масштаб ~ 1), а поперёк — очень быстро (масштаб ~ 100). Это создаёт эффективное число обусловленности $\sim 10^3$ вблизи минимума, что критично для методов первого порядка.

Таблица 4: Результаты на функции Розенброка, $x_0 = (-1.2, 1)$

Метод	Итер.	f -выч.	∇f -выч.	H -выч.	Сходимость	$f(x^*)$
CG (FR)	226	2979	227	0	Да	$1.9 \cdot 10^{-19}$
CG (PR)	1523	16703	1524	0	Да	$2.5 \cdot 10^{-18}$
Newton (Cholesky)	6	1	7	6	Да	$3.4 \cdot 10^{-20}$
Newton (direction)	21	48	44	21	Да	$7.7 \cdot 10^{-24}$
Dogleg	24	49	25	24	Да	$8.6 \cdot 10^{-22}$
DFP	50	120	101	0	Да	$5.4 \cdot 10^{-21}$
BFGS	35	90	71	0	Да	$4.3 \cdot 10^{-21}$
L-BFGS	35	100	119	0	Да	$4.7 \cdot 10^{-22}$

Таблица 5: Результаты на функции Розенброка, $x_0 = (0, 0)$

Метод	Итер.	f -выч.	∇f -выч.	H -выч.	Сходимость	$f(x^*)$
CG (FR)	216	2288	217	0	Да	$3.0 \cdot 10^{-18}$
CG (PR)	1063	11639	1064	0	Да	$1.0 \cdot 10^{-17}$
Newton (Cholesky)	2	1	3	2	Да	$4.9 \cdot 10^{-30}$
Newton (direction)	14	34	31	14	Да	$1.6 \cdot 10^{-21}$
Dogleg	15	31	16	15	Да	$9.7 \cdot 10^{-28}$
DFP	29	66	59	0	Да	$7.0 \cdot 10^{-20}$
BFGS	27	67	55	0	Да	$3.2 \cdot 10^{-23}$
L-BFGS	22	53	69	0	Да	$1.2 \cdot 10^{-26}$

Таблица 6: Результаты на функции Розенброка, $x_0 = (2, 2)$

Метод	Итер.	f -выч.	∇f -выч.	H -выч.	Сходимость	$f(x^*)$
CG (FR)	134	1337	135	0	Да	$8.2 \cdot 10^{-18}$
CG (PR)	1610	17744	1611	0	Да	$1.1 \cdot 10^{-17}$
Newton (Cholesky)	5	1	6	5	Да	$8.3 \cdot 10^{-30}$
Newton (direction)	15	36	33	15	Да	$2.0 \cdot 10^{-21}$
Dogleg	16	33	17	16	Да	$5.7 \cdot 10^{-23}$
DFP	8000	16072	16001	0	Нет	$3.0 \cdot 10^{-3}$
BFGS	48	127	97	0	Да	$4.6 \cdot 10^{-20}$
L-BFGS	46	114	144	0	Да	$1.7 \cdot 10^{-22}$

Newton-Cholesky показывает наилучшие результаты: 2–6 итераций, 1 вычисление функции. DFP не сходится из точки $(2, 2)$ за 8000 итераций (357 пропущенных обновлений матрицы). BFGS и L-BFGS стабильно сходятся из всех точек за 22–48 итераций. CG (PR) значительно медленнее FR из-за частых перезапусков.




Рис. 10: Траектории на функции Розенброка, $x_0 = (-1.2, 1)$




Рис. 11: Траектории на функции Розенброка, $x_0 = (0,0)$




Рис. 12: Траектории на функции Розенброка, $x_0 = (2, 2)$

4.3.2 Функция Химмельблау

Функция $f(x, y) = (x^2 + y - 11)^2 + (x + y^2 - 7)^2$ имеет 4 глобальных минимума: $(3, 2)$, $(-2.81, 3.13)$, $(-3.78, -3.28)$, $(3.58, -1.85)$, а также седловую точку вблизи начала координат. Точка $(0, 0)$ интересна тем, что гессиан в ней не является положительно определённым ($f(0, 0) = 170$, это не минимум), что позволяет протестировать устойчивость методов к некорректному гессиану.


Таблица 7: Результаты на функции Химмельблау, $x_0 = (0, 0)$

Метод	Итер.	f -выч.	∇f	H	Сход.	Найденный мин.
CG (FR)	442	4387	443	0	Да	$(3, 2)$
CG (PR)	32	250	33	0	Да	$(3, 2)$
Newton (Cholesky)	—	—	—	1	Нет	гессиан не PD
Newton (direction)	7	23	16	7	Да	$(3, 2)$
Dogleg	9	19	10	9	Да	$(3, 2)$
DFP	11	32	23	0	Да	$(3, 2)$
BFGS	10	32	21	0	Да	$(3, 2)$
L-BFGS	11	30	34	0	Да	$(3, 2)$

Таблица 8: Результаты на функции Химмельблау, остальные стартовые точки

Метод	x_0	Итер.	f -выч.	∇f	Сход.	Найденный мин.
Newton (Cholesky)	$(-3, 3)$	4	1	5	Да	$(-2.81, 3.13)$
Newton (direction)	$(-3, 3)$	4	9	9	Да	$(-2.81, 3.13)$
BFGS	$(-3, 3)$	6	24	13	Да	$(-2.81, 3.13)$
L-BFGS	$(-3, 3)$	5	17	16	Да	$(-2.81, 3.13)$
Newton (Cholesky)	$(3, -2)$	5	1	6	Да	$(3.58, -1.85)$
BFGS	$(3, -2)$	9	29	19	Да	$(3.58, -1.85)$
L-BFGS	$(3, -2)$	8	23	25	Да	$(3.58, -1.85)$
Newton (Cholesky)	$(-4, -4)$	5	1	6	Да	$(-3.78, -3.28)$
BFGS	$(-4, -4)$	9	31	19	Да	$(-3.78, -3.28)$
L-BFGS	$(-4, -4)$	8	23	25	Да	$(-3.78, -3.28)$

Все методы находят один из 4 минимумов функции Химмельблау в зависимости от начальной точки. Newton-Cholesky не может стартовать из $(0, 0)$, так как гессиан в этой точке не является положительно определённым. Метод Ньютона с выбором направления (Newton-direction) успешно справляется с этой ситуацией, переключаясь на антиградиент с линейным поиском.

Рис. 13: Траектории на функции Химмельблау, $x_0 = (0, 0)$




Рис. 14: Траектории на функции Химмельблау, $x_0 = (-3, 3)$




Рис. 15: Траектории на функции Химмельблау, $x_0 = (3, -2)$




Рис. 16: Траектории на функции Химмельблау, $x_0 = (-4, -4)$

4.4 Влияние размера памяти L-BFGS

Зачем этот эксперимент. Параметр памяти m в L-BFGS — ключевой компромисс: при $m = n$ метод эквивалентен полному BFGS, при $m = 1$ — близок к градиентному спуску. Задание требует исследовать, как m влияет на сходимость хотя бы на одной серии задач.

Исследовано влияние параметра памяти $m \in \{3, 5, 10, 20\}$ на квадратичной задаче размерности $n = 100$ с $\kappa = 1000$. Все конфигурации достигли лимита в 4000 итераций, не сойдясь. Однако при этом значение целевой функции практически одинаково ($f \approx -7751.27$), что говорит о медленной сходимости в последних итерациях.

Таблица 9: L-BFGS: влияние размера памяти ($n = 100$, $\kappa = 1000$)

Память m	Итер.	f -вызовы	∇f -вызовы	$\ \nabla f\ $
3	4000	316 284	8293	$1.60 \cdot 10^{-5}$
5	4000	313 436	8276	$1.73 \cdot 10^{-5}$
10	4000	307 635	8266	$1.08 \cdot 10^{-5}$
20	4000	320 003	8268	$1.13 \cdot 10^{-5}$

Увеличение памяти m не даёт значительного преимущества на этой задаче: все варианты близки к решению, но не достигают порога сходимости $\|\nabla f\| \leq 10^{-8}$.




Рис. 17: L-BFGS: итерации при разном размере памяти




Рис. 18: L-BFGS: вычисления функции при разном размере памяти

5 Сравнение методов

Таблица 10: Сравнительная характеристика методов

Метод	Гессиан	Память	Скорость сход.	Особенности
Quadratic CG	нет	$O(n)$	$\leq n$ шагов	только квадратичные
CG (FR/PR)	нет	$O(n)$	линейная	перезапуска, чувствителен к κ
Newton (Cholesky)	да	$O(n^2)$	квадратичная	требует PD гессиан
Newton (direction)	да	$O(n^2)$	квадратичная	робастнее Cholesky
Dogleg	да	$O(n^2)$	квадратичная	глобальная сходимость
DFP	нет	$O(n^2)$	суперлинейная	менее стабилен, чем BFGS
BFGS	нет	$O(n^2)$	суперлинейная	наиболее надёжный
L-BFGS	нет	$O(mn)$	суперлинейная	для больших n

6 Выводы

Влияние числа обусловленности

Число обусловленности κ по-разному влияет на разные классы методов:

- **Методы Ньютона** (Cholesky, direction, dogleg) *нечувствительны* к κ : 1 итерация на квадратичных задачах при любом κ и n . Используя точную информацию о кривизне (гессиан), они компенсируют плохую обусловленность.
- **Квадратичный CG** линейно зависит от κ : при $n = 100$ число итераций растёт от 1 ($\kappa = 1$) до 221 ($\kappa = 1000$), оставаясь $\leq n$.
- **Нелинейные CG (FR/PR)** крайне чувствительны: уже при $\kappa = 10$, $n = 10$ FR требует 99 итераций, а при $\kappa \geq 100$ и $n > 2$ оба метода не сходятся за 3000 итераций. Зигзагообразные траектории на плохо обусловленных задачах приводят к медленной сходимости.
- **Квазиньютоновские методы** (DFP, BFGS, L-BFGS) занимают промежуточное положение. На малых n (≤ 10) и умеренных κ (≤ 100) сходятся за 3–20 итераций. При больших n (≥ 50) и $\kappa \geq 10$ не успевают накопить достаточно кривизной информации за 3000 итераций.

Требование положительной определённости гессиана

- **Newton-Cholesky** строго требует PD гессиан. При нарушении (точка $(0,0)$ на Химмельблау) метод не может выполнить даже одну итерацию, т.к. разложение Холецкого не существует.
- **Newton-direction** обходит проблему: при неудачном разложении Холецкого переключается на направление антиградиента с линейным поиском (Вольфе). Это обеспечивает глобальную сходимость (7 итераций из $(0,0)$ на Химмельблау).
- **Dogleg** также требует PD гессиан для построения ньютоновского шага, но механизм области доверия и шаг Коши обеспечивают устойчивость. На Химмельблау из $(0,0)$ dogleg сходится за 9 итераций.
- **Квазиньютоновские методы** (DFP, BFGS, L-BFGS) не используют гессиан напрямую. Обновление аппроксимации B_k гарантирует PD при выполнении условия Вольфе ($y_k^T s_k > 0$).

Практические рекомендации

1. **Для квадратичных задач:** метод Ньютона (любая реализация) оптимален — 1 итерация. При недоступности гессиана — квадратичный CG (гарантированная сходимость за $\leq n$ шагов).
2. **Для гладких нелинейных функций малой размерности** ($n \leq 50$): BFGS — лучший баланс надёжности и скорости. Стабильно сходится на Розенброке (27–48 итераций) и Химмельблау (6–10 итераций) без вычисления гессиана.
3. **Для задач с возможным не-PD гессианом:** Newton-direction или dogleg предпочтительнее Newton-Cholesky. Dogleg обеспечивает глобальную сходимость через адаптивный радиус доверия.
4. **DFP** уступает BFGS на сложных ландшафтах (не сходится на Розенброке из $(2, 2)$) и не рекомендуется.
5. **L-BFGS** оправдан при большом n , когда хранение полной матрицы $O(n^2)$ невозможно. Однако на плохо обусловленных задачах ($\kappa = 1000$, $n = 100$) L-BFGS не сходится за 4000 итераций при любом $m \in \{3, 5, 10, 20\}$.
6. **Нелинейные CG** рекомендуются только для хорошо обусловленных задач ($\kappa \leq 10$) малой размерности. FR даёт более предсказуемое поведение, PR — больше перезапусков, но иногда быстрее (Химмельблау из $(0, 0)$: PR за 32 итерации vs FR за 442).